

Metody Analizy Danych – projekt drugi

Jaki analizę należy wykonać?

- Klasyfikacja

Dane: własne dane, repozytoria Machine Learningu (np. UCI), dane z pakietów w R

Wymagania zbioru: minimum 10 zmiennych, minimum 800 obserwacji

Grupy maksymalnie 5 osobowe

Co powinno znaleźć się w projekcie?

- Tytuł pracy
- Autorzy/Autor
- Streszczenie (maksymalnie 150 słów)
- Słowa kluczowe
- Wprowadzenie
- Przedmiot badania
 - Cel
 - Wstępna analiza danych
 - Przedstawienie dostępnych zmiennych
 - statystyki opisowe (przynajmniej: średnia, mediana, minimum, maksimum, odchylenie standardowe, skośność)
 - podstawowa wizualizacja – np. boxplot, histogramy
 - transformacje danych (skalowanie, logarytmowanie)
 - braki danych – czy występują i jak je obsłużono
 - obserwacje odstające i w jaki sposób je obsłużono
- Opis metod
 - minimum trzy metody i stworzenie modelu hybrydowego (np. średnia ważona score'ów z metod), formalnie więc: minimum cztery mechanizmy decyzyjne
 - cytowanie pracy, w której zaproponowano metodę (ewentualnie pracy, w której użyto metodę) i opis ogólny działania metody
- Rezultaty
 - Mierniki (np. AUC, Accuracy, F1 Score) – minimum jeden
 - Sposób walidacji (np. krzyżowa, leave-one-out, wielokrotne próbkowanie) – minimum jeden sposób
- Przykład użycia modeli na stworzonych sztucznie obserwacjach
- Bibliografia

Co należy oddać?

- Zbiór danych + Plik z opisem (pdf) + plik z obliczeniami (w zależności od tego, gdzie wykonane to .R, .py, .xlsx)

lub

- Zbiór danych + Jupyter Notebook (.ipynb i wygenerowany .html)

lub

- Zbiór danych + R Notebook (.Rmd i wygenerowany .html)

Jak sformatować plik z opisem?

Sugerowane formatowanie podobne do artykułu naukowego z wybranego czasopisma (bez limitu stron). Przykładowo: http://qme.sggw.pl/wp-content/uploads/MIBE_Szablon2019.docx

Pliki z projektem powinny zostać załadowane na MS Teams bez archiwizowania.